

Rapport synthétique métier

Prédiction du rendement agricole (tonnes / hectare)

Contexte et objectif

Ce projet prédit le rendement agricole d'une parcelle à partir de ses caractéristiques : région, type de sol, culture, météo, usage d'irrigation et d'engrais. L'objectif métier est d'anticiper la récolte pour mieux calibrer les achats d'intrants, les engagements commerciaux et l'allocation des ressources (eau, engrais).

Le modèle retenu (Explainable Boosting Machine, EBM) explique 91% de la variance du rendement sur des données jamais vues à l'entraînement, avec une erreur moyenne d'environ 0,50 tonne/hectare. Il a été préféré à des modèles légèrement plus complexes car il offre les mêmes performances tout en restant entièrement explicable variable par variable un atout pour justifier les prédictions auprès des experts agronomiques.

$R^2 = 0,91$ Variance du rendement expliquée (test)	0,50 t/ha Erreur moyenne (RMSE, test)	EBM Modèle retenu (Interprétable)
---	---	---

Rendement moyen observé

Sur les 1 000 000 de parcelles du jeu de données, le rendement moyen est de 4,65 t/ha (écart-type 1,70), pour une plage observée d'environ 0 à 10 t/ha, sur 6 cultures (orge, coton, maïs, riz, soja, blé), 4 régions et 6 types de sol.

Comparaison des modèles (données de test)

Sept approches ont été comparées à base égale (mêmes données d'entraînement/test). Les screenshot du fichier screen montre les résultats obtenus sur le jeu de test.

Les écarts entre les 5 premiers modèles sont inférieurs à 1% : aucun ne se distingue nettement en performance pure. EBM a été choisi malgré une performance quasi identique car c'est, avec la régression linéaire (trop simple pour ce cas d'usage), le seul modèle du comparatif nativement interprétable : chacune de ses prédictions peut être décomposée et justifiée variable par variable auprès d'un expert agronomique.

Qu'est-ce que le « coût métier » ?


Cette métrique traduit l'impact économique des erreurs de prédiction : une sur-estimation du rendement (engagements de vente non tenus, pénalités) coûte 2 fois plus cher qu'une sous-estimation (ventes non anticipées, manque à gagner). Elle guide le choix et le réglage du modèle davantage qu'une simple mesure d'erreur moyenne.

L'analyse SHAP ci-dessous montre, pour un échantillon de parcelles de test, comment chaque

variable pousse la prédiction au-dessus (points roses) ou en dessous (points bleus) du rendement moyen. Les variables sont classées par importance décroissante.

Conclusion interprétation

La pluviométrie (Rainfall_mm) est de loin le facteur le plus déterminant, plus il pleut, plus le rendement prédit augmente, sur toute la plage de valeurs observée. L'usage d'engrais et l'usage d'irrigation arrivent juste après : leur présence pousse systématiquement la prédiction à la hausse, leur absence à la baisse. La température a un effet plus modéré et moins linéaire.



La région, le type de sol et le nombre de jours jusqu'à la récolte ont un effet marginal en comparaison des quatre variables précédentes.

Recommandations

Prioriser l'irrigation dans les zones ou périodes à faible pluviométrie : c'est le levier n°1 identifié par le modèle, avant tout autre facteur agronomique.

Maintenir un usage systématique de l'engrais et de l'irrigation : leur absence pénalise le rendement de façon nette et constante, quelle que soit la parcelle.

Calibrer les engagements commerciaux avec prudence : une surestimation du rendement coûte 2 fois plus cher qu'une sous-estimation. Utiliser la prédiction du modèle comme un plancher plutôt qu'une moyenne pour les engagements de vente.

Investir en priorité dans la qualité de la donnée pluviométrique locale (capteurs, fréquence de

mesure) : vu son poids dominant dans le modèle, l'améliorer a plus d'impact sur la précision des prédictions que tout autre investissement data.

Exploiter l'interprétabilité du modèle EBM pour justifier chaque prédiction auprès des agronomes et affiner progressivement la confiance des équipes terrain dans l'outil.

Limites à connaître avant un déploiement large

Le jeu de données principal (1M de parcelles) est en partie simulé, le proxy pesticide est agrégé par culture et non par parcelle. Ces recommandations gagnent à être validées sur un échantillon de parcelles réelles avant généralisation à grande échelle.